Datenanalyse

Data Analysis

Grundlagen

Methodische Grundlagen der Datenanalyse

Fragestellung

Festlegung des Problems

Bestimmung der relevanten Kennzahlen

Was treibt die Kunden zufriedenheit?

Erhebung

Sammlung von Daten Datenbanken, APIs, Web Scraping

Produktbewertungen
Lieferzeiten
Preise & Rabatte

Vorbereitung

Bereinigung Fehlende Werte oder unvollständiger Daten

Transformation und strukturierung der Rohdaten

Z.b. EUR, USD

Analyse

Statistische Auswertung

Korrelationen

Mustererkennung

Anwendung von Modellen zur Erkenntnisgewinnung

Teilen

Berichte

Präsentationen

Storytelling mit Daten

Klare Empfehlungen geben

Methodische Grundlagen der Datenanalyse

Setup, Daten & Datentypen
- Python, Jupyter Notebook, Bibliotheken installieren, VSCode
- Arbeiten mit Jupyter | Überblick über Datentypen
- Data | Information | Dataset

Analyseziele & KPIs definieren
- Analysefragen & Ziele identifizieren
- KPIs mit Geschäftsentscheidungen verknüpfen

Datenerhebung & Datenqualität
- Daten sammeln: APIs, lokale Dateien, unstrukturierte Daten
- Vollständigkeit, Genauigkeit, Konsistenz prüfen
- Daten laden & inspizieren
- Fehlende Werte, Duplikate, Format prüfen

Datenbereinigung & -vorbereitung
- Fehlende/falsche Werte korrigieren
- Formate standardisieren
- Variablen für Analyse transformieren

Datenmodellierung & Aggregation
- Daten in Tabellen & Beziehungen organisieren
- Feature Engineering & Aggregationen

Deskriptive Statistik & KPIs
Mittelwert, Median, Modus, Standardabweichung, Spannweite
Korrelationen & Kreuztabellen

Datenvisualisierung
- Klassische Diagramme; Balkendiagramm, Histogramm, Boxplot, Liniendiagramm, Streudiagramm
- Interaktive Charts

Analytics-Workflow & Integration
- Strukturierter Workflow
- Mini-Fallbeispiele mit allen vorherigen Schritten

Capstone End-to-End Projekt
- Vollständige Analyse von der Fragestellung bis zur Präsentation
- Alle erlernten Schritte anwenden
- Ergebnisse präsentieren & diskutieren

Methodische Grundlagen der Datenanalyse

Setup, Daten & Datentypen
- **Python, Jupyter Notebook, Bibliotheken installieren, VSCode**
- **Arbeiten mit Jupyter | Überblick über Datentypen**
- **Data | Information | Dataset**

Analyseziele & KPIs definieren
- **Analysefragen & Ziele identifizieren**
- **KPIs mit Geschäftsentscheidungen verknüpfen**

Datenerhebung & Datenqualität
- Daten sammeln: APIs, lokale Dateien, unstrukturierte Daten
- Vollständigkeit, Genauigkeit, Konsistenz prüfen
- Daten laden & inspizieren
- Fehlende Werte, Duplikate, Format prüfen

Datenbereinigung & -vorbereitung
- Fehlende/falsche Werte korrigieren
- Formate standardisieren
- Variablen für Analyse transformieren

Datenmodellierung & Aggregation
- Daten in Tabellen & Beziehungen organisieren
- Feature Engineering & Aggregationen

Deskriptive Statistik & KPIs
Mittelwert, Median, Modus, Standardabweichung, Spannweite
Korrelationen & Kreuztabellen

Datenvisualisierung
- Klassische Diagramme; Balkendiagramm, Histogramm, Boxplot, Liniendiagramm, Streudiagramm
- Interaktive Charts

Analytics-Workflow & Integration
- Strukturierter Workflow
- Mini-Fallbeispiele mit allen vorherigen Schritten

Capstone End-to-End Projekt
- Vollständige Analyse von der Fragestellung bis zur Präsentation
- Alle erlernten Schritte anwenden
- Ergebnisse präsentieren & diskutieren

Methodische Grundlagen der Datenanalyse

Setup, Daten & Datentypen
- Python, Jupyter Notebook, Bibliotheken installieren, VSCode
- Arbeiten mit Jupyter | Überblick über Datentypen
- Data | Information | Dataset

Analyseziele & KPIs definieren
- Analysefragen & Ziele identifizieren
- KPIs mit Geschäftsentscheidungen verknüpfen

Datenerhebung & Datenqualität
- **Daten sammeln: APIs, lokale Dateien, unstrukturierte Daten**
- **Vollständigkeit, Genauigkeit, Konsistenz prüfen**
- **Daten laden & inspizieren**
- **Fehlende Werte, Duplikate, Format prüfen**

Datenbereinigung & -vorbereitung
- Fehlende/falsche Werte korrigieren
- Formate standardisieren
- Variablen für Analyse transformieren

Datenmodellierung & Aggregation
- Daten in Tabellen & Beziehungen organisieren
- Feature Engineering & Aggregationen

Deskriptive Statistik & KPIs
Mittelwert, Median, Modus, Standardabweichung, Spannweite
Korrelationen & Kreuztabellen

Datenvisualisierung
- Klassische Diagramme; Balkendiagramm, Histogramm, Boxplot, Liniendiagramm, Streudiagramm
- Interaktive Charts

Analytics-Workflow & Integration
- Strukturierter Workflow
- Mini-Fallbeispiele mit allen vorherigen Schritten

Capstone End-to-End Projekt
- Vollständige Analyse von der Fragestellung bis zur Präsentation
- Alle erlernten Schritte anwenden
- Ergebnisse präsentieren & diskutieren

Methodische Grundlagen der Datenanalyse

Setup, Daten & Datentypen
- Python, Jupyter Notebook, Bibliotheken installieren, VSCode
- Arbeiten mit Jupyter | Überblick über Datentypen
- Data | Information | Dataset

Analyseziele & KPIs definieren
- Analysefragen & Ziele identifizieren
- KPIs mit Geschäftsentscheidungen verknüpfen

Datenerhebung & Datenqualität
- Daten sammeln: APIs, lokale Dateien, unstrukturierte Daten
- Vollständigkeit, Genauigkeit, Konsistenz prüfen
- Daten laden & inspizieren
- Fehlende Werte, Duplikate, Format prüfen

Datenbereinigung & -vorbereitung
- **Fehlende/falsche Werte korrigieren**
- **Formate standardisieren**
- **Variablen für Analyse transformieren**

Datenmodellierung & Aggregation
- Daten in Tabellen & Beziehungen organisieren
- Feature Engineering & Aggregationen

Deskriptive Statistik & KPIs

Mittelwert, Median, Modus, Standardabweichung, Spannweite
Korrelationen & Kreuztabellen

Datenvisualisierung
- Klassische Diagramme; Balkendiagramm, Histogramm, Boxplot, Liniendiagramm, Streudiagramm
- Interaktive Charts

Analytics-Workflow & Integration
- Strukturierter Workflow
- Mini-Fallbeispiele mit allen vorherigen Schritten

Capstone End-to-End Projekt
- Vollständige Analyse von der Fragestellung bis zur Präsentation
- Alle erlernten Schritte anwenden
- Ergebnisse präsentieren & diskutieren

Methodische Grundlagen der Datenanalyse

Setup, Daten & Datentypen
- Python, Jupyter Notebook, Bibliotheken installieren, VSCode
- Arbeiten mit Jupyter | Überblick über Datentypen
- Data | Information | Dataset

Analyseziele & KPIs definieren
- Analysefragen & Ziele identifizieren
- KPIs mit Geschäftsentscheidungen verknüpfen

Datenerhebung & Datenqualität
- Daten sammeln: APIs, lokale Dateien, unstrukturierte Daten
- Vollständigkeit, Genauigkeit, Konsistenz prüfen
- Daten laden & inspizieren
- Fehlende Werte, Duplikate, Format prüfen

Datenbereinigung & -vorbereitung
- Fehlende/falsche Werte korrigieren
- Formate standardisieren
- Variablen für Analyse transformieren

Datenmodellierung & Aggregation
- **Daten in Tabellen & Beziehungen organisieren**
- **Feature Engineering & Aggregationen**

Deskriptive Statistik & KPIs
Mittelwert, Median, Modus, Standardabweichung, Spannweite
Korrelationen & Kreuztabellen

Datenvisualisierung
- Klassische Diagramme; Balkendiagramm, Histogramm, Boxplot, Liniendiagramm, Streudiagramm
- Interaktive Charts

Analytics-Workflow & Integration
- Strukturierter Workflow
- Mini-Fallbeispiele mit allen vorherigen Schritten

Capstone End-to-End Projekt
- Vollständige Analyse von der Fragestellung bis zur Präsentation
- Alle erlernten Schritte anwenden
- Ergebnisse präsentieren & diskutieren

Data Storage Architectures / Solutions

Data Warehouse – optimized for structured, relational data; supports complex analytics and reporting.

Data Lake – can store structured, semi-structured, and unstructured data; schema-on-read; good for flexible analysis and large-scale storage.

Object Storage – primarily for unstructured data like files, images, videos, or backups; highly scalable and cost-effective.

Feature	Data Warehouse	Data Lake	Object Storage
Data types	Structured	Structured, semi-structured, unstructured	Mostly unstructured
Schema	Schema-on-write	Schema-on-read	None
Access / Query	SQL queries	SQL/Spark queries + APIs	APIs

Data Modeling Basics

- **Definition:** Designing a **blueprint of how data is organized** so it can be stored, retrieved, and used efficiently.

- Traditionally involves **entities, relationships, attributes, and constraints**.

- **Classic example:** Designing tables in a relational database with primary keys, foreign keys, and normalization.

Step-by-Step Data Modeling

Identify Entities (Objects / Things)

1. Determine the main “objects” in your domain.
2. Examples:
    1. Online store → Customer, Order, Product
    2. Stock exchange → Stock, Trade, Trader

Identify Attributes (Properties of Entities)

1. List the data points each entity needs.
2. Examples:
    1. Customer → Name, Email
    2. Stock → Symbol, CompanyName

Determine Relationships Between Entities

1. Decide how entities are linked:
    1. One-to-One (1:1)
    2. One-to-Many (1:N)
    3. Many-to-Many (M:N, usually needs a linking table)
2. Example: Trader → Trade = 1:N

Assign Keys (Optional in Conceptual Phase)

1. Primary Key (PK) → unique identifier for each entity
2. Foreign Key (FK) → links to another entity

Draw a Conceptual Diagram

1. Boxes for entities, list attributes, arrows for relationships
2. Keep it **high-level**, no need to define data types yet

Determine Relationships Between Entities

1:1 – Trader → Trading Account
•Each trader has **one trading account**, each account belongs to **one trader**.

1:N – Trader → Trade
•One trader can make **many trades**, each trade belongs to **one trader**.

M:N – Trade → Stock
•One trade can include **many stocks**, one stock can appear in **many trades** (via a linking table, e.g., TradeDetails).

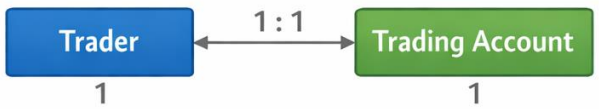

1:1 Relationship
Trader ⟷ Trading Account

1:N Relationship
Trader ⟶ Trade

M:N Relationship (Many-to-Many)
Trade ⟷ TradeDetails ⟷ Stock